

Análisis Exploratorio de Datos (EDA)

Instituto Tecnológico Superior de Ciudad Constitución
Ingeniería en Sistemas Computacionales

1. ¿Qué es EDA en Ciencia de Datos?

El **Análisis Exploratorio de Datos** (Exploratory Data Analysis, EDA) es una etapa inicial y fundamental dentro del proceso de ciencia de datos. Consiste en examinar los datos de forma sistemática mediante técnicas estadísticas y visuales antes de aplicar modelos predictivos o inferenciales. El concepto fue formalizado por el estadístico **John W. Tukey** en su obra *Exploratory Data Analysis* (1977), quien argumentó que los datos deben observarse antes de ser modelados.

En la práctica moderna, el EDA constituye entre el 60 y el 80 por ciento del tiempo total de un proyecto de análisis de datos, ya que los hallazgos obtenidos determinan las decisiones de limpieza, transformación y selección de modelos.

Finalidades y objetivos

Objetivo	Descripción
Comprender la estructura	Conocer dimensiones, tipos de dato y cantidad de registros del conjunto de datos.
Detectar valores atípicos	Identificar outliers que puedan distorsionar estadísticas y modelos.
Identificar valores faltantes	Localizar campos vacíos o nulos para definir estrategias de imputación.
Analizar distribuciones	Entender cómo se distribuyen los valores de cada variable (normal, sesgada, etc.).
Descubrir relaciones	Encontrar correlaciones o dependencias entre pares o grupos de variables.
Validar supuestos	Verificar si los datos cumplen requisitos de los modelos estadísticos a aplicar.
Generar hipótesis	Formular preguntas que guíen etapas posteriores del análisis.

Fuente: Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.

2. Fases y Tipos de EDA

2.1 Fases del proceso EDA

Fase	Nombre	Actividades principales
1	Inspección inicial	Revisar shape, dtypes, head(), describe(). Entender el dominio del problema.
2	Análisis de calidad	Detectar nulos, duplicados, errores de formato e inconsistencias.
3	Análisis univariado	Estudiar cada variable individualmente: media, mediana, moda, histogramas, boxplots.


4	Análisis bivariado	Examinar relaciones entre pares de variables: scatter plots, correlaciones, tablas cruzadas.
5	Análisis multivariado	Evaluar patrones con múltiples variables: pairplots, heatmaps, PCA exploratorio.
6	Conclusiones	Documentar hallazgos, anomalías y decisiones de preprocesamiento para el modelado.

2.2 Tipos de EDA

Dimensión de clasificación	Tipo	Descripción
Según el método	Gráfico	Usa visualizaciones: histogramas, boxplots, scatter plots, heatmaps.
Según el método	No gráfico	Usa estadísticas numéricas: medias, varianzas, tablas de frecuencia.
Según las variables	Univariado	Analiza una variable a la vez de forma aislada.
Según las variables	Bivariado	Analiza la relación entre exactamente dos variables.
Según las variables	Multivariado	Analiza patrones involucrando tres o más variables simultáneamente.

2.3 Esquema del proceso EDA

El siguiente diagrama resume el flujo completo de un EDA estándar, desde la carga de datos hasta las conclusiones que alimentan el modelado.



Fuente: McKinney, W. (2022). Python for Data Analysis, 3rd ed. O'Reilly Media.

3. Herramientas más utilizadas para EDA

El ecosistema de herramientas para EDA es amplio. A continuación se presentan las más adoptadas en la industria y la academia, tanto en entornos de programación como en plataformas visuales.

Herramienta	Lenguaje / Entorno	Función principal
Pandas	Python	Manipulación y resumen de datos tabulares (DataFrames).
NumPy	Python	Operaciones numéricas, estadísticas vectorizadas y matrices.
Matplotlib	Python	Visualizaciones estáticas de bajo nivel: líneas, barras, histogramas.
Seaborn	Python	Gráficos estadísticos de alto nivel basados en Matplotlib.
Plotly	Python / JS	Gráficos interactivos y dashboards en el navegador.
ydata-profiling	Python	Genera automáticamente un reporte EDA completo con una línea de código.
SciPy	Python	Pruebas estadísticas: normalidad, correlación, ANOVA.
R + ggplot2	R	Visualización estadística declarativa ampliamente usada en academia.
Tableau	Visual/GUI	Exploración interactiva sin código, orientada a negocio.
Power BI	Visual/GUI	Análisis y dashboards integrados con el ecosistema Microsoft.
Jupyter Notebook	Entorno	Combina código, visualizaciones y narrativa en un solo documento.

Fuente: VanderPlas, J. (2016). *Python Data Science Handbook*. O'Reilly Media.

4. Ejemplo de EDA en Python — Dataset Iris

Se aplica un EDA completo sobre el dataset **Iris** (Fisher, 1936), que contiene 150 registros de flores de tres especies con cuatro variables numéricas: longitud y ancho de sépalo y pétalo.

4.1 Carga e inspección inicial

```
import pandas as pd, numpy as np
import matplotlib.pyplot as plt, seaborn as sns
from sklearn.datasets import load_iris

iris = load_iris(as_frame=True)
df = iris.frame
df['species'] = df['target'].map({0:'setosa',1:'versicolor',2:'virginica'})
df.drop(columns='target', inplace=True)

print(df.shape)          # (150, 5)
print(df.dtypes)
print(df.describe())
```

Resumen estadístico obtenido:

Variable	count	mean	std	min	25%	50%	75%	max
sepal length (cm)	150	5.84	0.83	4.30	5.10	5.80	6.40	7.90
sepal width (cm)	150	3.06	0.44	2.00	2.80	3.00	3.30	4.40
petal length (cm)	150	3.76	1.77	1.00	1.60	4.35	5.10	6.90
petal width (cm)	150	1.20	0.76	0.10	0.30	1.30	1.80	2.50

4.2 Análisis de calidad de datos


```
print(df.isnull().sum())      # 0 nulos en todas las columnas
print(df.duplicated().sum())  # 1 duplicado detectado
print(df['species'].value_counts())
# setosa: 50 | versicolor: 50 | virginica: 50
```

El dataset no presenta valores nulos. Se detecta un registro duplicado que puede eliminarse con `df.drop_duplicates()`. Las clases están perfectamente balanceadas (50 registros por especie).

4.3 Análisis univariado — Distribuciones

```
fig, axes = plt.subplots(2, 2, figsize=(10, 6))
for i, col in enumerate(num_cols):
    axes.flatten()[i].hist(df[col], bins=20, color='steelblue', edgecolor='white')
    axes.flatten()[i].set_title(col)
plt.suptitle('Distribución de variables numéricas')
plt.tight_layout()
```

Distribución de variables numéricas




Las variables de sépalo muestran distribuciones aproximadamente normales. Las variables de pétalo presentan distribución bimodal, lo que refleja la separación entre la especie *setosa* y las demás.

4.4 Análisis univariado — Boxplots por especie

```
for i, col in enumerate(num_cols):
    sns.boxplot(data=df, x='species', y=col, ax=axes[i], palette='Set2')
```


Boxplots por especie



Los boxplots confirman que *setosa* tiene pétalos notablemente más pequeños. Se observan valores atípicos leves en *sepal width* para la clase *versicolor*.

4.5 Análisis bivariado — Matriz de correlación

```
corr = df[num_cols].corr()  
sns.heatmap(corr, annot=True, fmt='.2f', cmap='coolwarm', square=True)
```



La correlación entre *petal length* y *petal width* es de **0.96**, la más alta del dataset. Ambas variables de pétalo correlacionan también fuertemente con *sepal length* (0.87 y 0.82 respectivamente). Las variables de sépalo entre sí tienen correlación débil (−0.12).

4.6 Análisis multivariado — Pairplot

```
sns.pairplot(df, hue='species', palette='Set1', diag_kind='kde')
```



El pairplot confirma que la especie *setosa* es linealmente separable del resto en el espacio de las variables de pétalo. Las clases *versicolor* y *virginica* presentan cierto traslape en todas las combinaciones de variables.

4.7 Conclusiones del EDA

#	Hallazgo
1	El dataset no contiene valores nulos; existe un duplicado menor que puede eliminarse.
2	Las clases están perfectamente balanceadas (50 muestras por especie).
3	Petal length y petal width tienen una correlación de 0.96 — posible redundancia.
4	Setosa es linealmente separable por sus variables de pétalo (clasificación fácil).
5	Las distribuciones bimodales de pétalo sugieren que esta variable es muy discriminativa.
6	Se recomienda usar petal length y petal width como variables predictoras principales.

Referencias

Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.

McKinney, W. (2022). *Python for Data Analysis*, 3rd ed. O'Reilly Media.

VanderPlas, J. (2016). *Python Data Science Handbook*. O'Reilly Media.

Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2), 179–188.

Pandas Development Team. (2024). *pandas documentation*. <https://pandas.pydata.org/docs/>

Waskom, M. (2021). Seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.