

INSTITUTO TECNOLÓGICO SUPERIOR DE CIUDAD CONSTITUCION.

INGENIERIA EN SISTEMAS COMPUTACIONALES.

8SM

CIENCIA DE DATOS

REPORTE

PIPELINE DE ETL CON PYTHON, SQLITE3 Y EXPRESIONES
REGULARES

ALUMNO:
CONTRERAS GOMEZ, ALEJANDRO.

TUTOR:
ISAAC FELIPE GARCIA LOPEZ.

CD. CONSTITUCION – BAJA CALIFORNIA SUR – MEXICO.
VIERNES 22 DE MAYO DEL 2026.

1. Descripcion general

El codigo implementa un pipeline ETL (Extract, Transform, Load) sobre un archivo CSV llamado members.csv. El objetivo es cargar los datos en una base de datos SQLite3, aplicar transformaciones de limpieza y estandarizacion sobre columnas especificas usando expresiones regulares, y finalmente persistir el resultado en una tabla nueva dentro de la misma base de datos.

2. Extraccion

Funcion: load_csv_to_sqlite

Se lee el archivo members.csv con la libreria pandas mediante `pd.read_csv`. El DataFrame resultante se inserta en una base de datos SQLite3 local usando el metodo `to_sql`, creando la tabla members. Si la tabla ya existe, se reemplaza. La funcion retorna la conexion activa para ser usada en las etapas siguientes.

3. Transformacion

Esta etapa aplica cuatro funciones independientes sobre el DataFrame. Cada una modifica o enriquece una columna especifica usando expresiones regulares.

3.1 Extraccion de codigo postal

Funcion: extract_postal_code

Lee la columna address y extrae el codigo postal usando `str.extract` con el patron `\b(\d{4,6})\b`. Este patron busca una secuencia de 4 a 6 digitos delimitada por bordes de palabra. El resultado se almacena en una nueva columna llamada postal_code.

3.2 Limpieza del numero telefonico

Funcion: clean_phone_number

Se aplican seis pasos en orden sobre la columna phone_number:

Paso 1. Se detectan y anulan valores negativos corruptos que vienen directamente del CSV (por ejemplo -1327), usando el patron `^-\\d+$`. Estos se convierten a NULL.

Paso 2. Se eliminan los simbolos +, (y) mediante la clase de caracteres `[+()]`.

Paso 3. Los guiones internos entre digitos se reemplazan por espacios usando el patron `(?<=\\d)-(?!\\d)`, que utiliza lookbehind y lookahead para asegurarse de no afectar otros contextos.

Paso 4. Se corrige el prefijo de pais duplicado (62 62) que aparece cuando el numero original tenia la forma +62 (62)..., reduciendolo a un solo 62.

Paso 5. Se elimina el cero redundante que algunos numeros tienen tras el prefijo de pais, como 62 0748, convirtiendolo a 62 748.

Paso 6. Espacios multiples consecutivos se reducen a uno solo con el patron `\\s{2,}`.

3.3 Formato de fecha de nacimiento

Funcion: `format_birth_date`

Convierte la columna `birth_date` al formato estandar DD/MM/AAAA. El patron utilizado es `(\d{1,2})[-\s]([a-zA-Z]+)[- \s](\d{2,4})`, que captura tres grupos: el dia, el nombre del mes en texto y el año. El separador acepta tanto guion como espacio, lo que cubre los dos formatos presentes en el CSV (por ejemplo 05-feb-91 y 22 Apr 1994). El nombre del mes se convierte a minusculas y se mapea a su numero correspondiente mediante un diccionario. Si el año tiene dos digitos, se expande a cuatro: valores mayores a 25 se asumen del siglo XX y los demas del siglo XXI.

3.4 Calculo de edad

Funcion: `calculate_age`

Lee la columna `register_time`, que contiene un timestamp Unix (segundos desde el 1 de enero de 1970). Convierte ese valor a un objeto `datetime` usando `datetime.fromtimestamp` y calcula la diferencia en dias respecto a la fecha actual. El resultado se almacena en una nueva columna `age_years`. Si el valor no puede procesarse, se devuelve `None`.

4. Carga

Funcion: `load_transformed_to_sqlite`

El DataFrame transformado se guarda en la misma base de datos SQLite3 bajo una tabla nueva llamada `members_clean`, usando `to_sql` con `if_exists='replace'`. Esto permite consultar los datos limpios con SQL estandar sin modificar la tabla original.

5. Pipeline principal

Funcion: `run_etl`

Orquesta las tres etapas en orden: primero llama a `load_csv_to_sqlite` para la extraccion, luego aplica las cuatro funciones de transformacion y finalmente ejecuta `load_transformed_to_sqlite` para la carga. Incluye pausas interactivas con `input()` entre cada etapa para que el usuario pueda revisar el estado del proceso en consola.

6. Consulta de verificacion

Funcion: `query_examples`

Abre una nueva conexion a la base de datos y ejecuta un `SELECT *` sobre la tabla `members_clean` ordenando por apellido. Imprime el resultado completo en consola para verificar que los datos transformados se almacenaron correctamente.

7. Herramientas utilizadas

Python 3: lenguaje principal del proyecto.

pandas: lectura del CSV, manipulacion del DataFrame y aplicacion de transformaciones con `str.extract` y `str.replace`.

sqlite3: modulo de la libreria estandar de Python para crear y consultar la base de datos local.

re: modulo de expresiones regulares, utilizado directamente en la funcion de formato de fecha.

datetime: conversion de timestamps Unix a fechas legibles y calculo de diferencias de tiempo.