

INSTITUTO TECNOLÓGICO SUPERIOR DE CIUDAD CONSTITUCIÓN.

INGENIERÍA EN SISTEMAS COMPUTACIONALES.

8SM

CIENCIA DE DATOS

GLOSARIO

ALUMNO:

ALEJANDRO CONTRERAS GOMEZ.

TUTOR:

ISAAC FELIPE GARCIA LOPEZ.

CD. CONSTITUCIÓN – BAJA CALIFORNIA SUR – MÉXICO.

VIERNES 05 DE JUNIO DEL 2026.

A

Agrupación: Operación que organiza registros de un dataset en subconjuntos con base en el valor de una o más columnas, usando métodos como `groupby()` de Pandas para aplicar funciones de resumen por categoría.

Álgebra lineal: Rama de las matemáticas que estudia vectores, matrices y las transformaciones lineales entre espacios vectoriales; es la base computacional de muchos algoritmos de machine learning y análisis de datos.

Análisis de datos: La recopilación, transformación y organización de los datos para sacar conclusiones, hacer predicciones e impulsar una toma de decisiones fundamentada.

Análisis bivariado: Estudio de la relación entre dos variables del dataset, mediante correlaciones, gráficas de dispersión o tablas cruzadas para identificar dependencias o patrones conjuntos.

Análisis multivariado: Técnica estadística que examina simultáneamente tres o más variables para descubrir patrones, correlaciones y estructuras complejas en un conjunto de datos.

Análisis univariado: Examinación de una sola variable a la vez mediante medidas de tendencia central, dispersión e histogramas, para entender su distribución individual.

Análisis (computacional) de datos: La ciencia de los datos aplicada mediante herramientas computacionales para procesar grandes volúmenes de información de forma automatizada.

Analista de datos: Alguien que recopila, transforma y organiza los datos para impulsar la toma de decisiones fundamentada.

Aprendizaje: Proceso mediante el cual un modelo ajusta sus parámetros a partir de datos de entrenamiento para mejorar su desempeño en una tarea específica.

Array: Estructura de datos que almacena colecciones de elementos del mismo tipo en posiciones contiguas de memoria, indexados por uno o más enteros; en NumPy es el tipo `ndarray`.

B

Big data: Conjuntos de datos de tan gran volumen, variedad y velocidad que superan la capacidad de herramientas convencionales para capturarlos, gestionarlos y procesarlos en un tiempo razonable.

Boxplot: Diagrama de caja y bigotes que resume la distribución de un conjunto de datos mostrando la mediana, cuartiles, rango intercuartílico y valores atípicos.

C

Carga de datos: Fase final del proceso ETL en la que los datos ya transformados son escritos en un destino final, como una base de datos, tabla SQL o archivo, para su consumo posterior.

Ciencia: Conjunto de conocimientos ordenados y verificables obtenidos mediante la observación sistemática, la experimentación y el razonamiento lógico.

Ciencia de datos: Un campo de estudio que utiliza datos brutos para crear nuevas formas de modelar y entender lo desconocido.

Columna: Atributo o variable en un dataset tabular que representa una característica específica de cada registro; en Pandas corresponde a una Series dentro de un DataFrame.

Concatenación: Operación que une dos o más arrays o DataFrames a lo largo de un eje determinado (filas o columnas), como con `np.vstack()`, `np.hstack()` o `pd.concat()`.

Conexión: Enlace establecido entre un programa y una base de datos mediante un objeto como `sqlite3.connect()`, que permite ejecutar consultas y manipular datos.

Conjunto de datos: Una colección de datos que pueden ser manipulados o analizados como una unidad.

Constantes: Valores fijos que no cambian durante la ejecución de un programa; en ciencia de datos se usan para definir umbrales, semillas de aleatoriedad o parámetros de configuración.

Correlación: Medida estadística que expresa el grado de relación lineal entre dos variables numéricas, con valores entre -1 y 1 ; se visualiza frecuentemente con mapas de calor (heatmaps).

CSV: Formato de archivo de texto plano donde los valores de cada fila están separados por comas; ampliamente utilizado para intercambiar datos tabulares entre herramientas.

Cualitativos (Datos): Datos que describen categorías o cualidades no numéricas, como el género, la ciudad o el nivel educativo, y que requieren codificación para ser procesados por modelos numéricos.

Cuantitativos (Datos): Datos expresados en valores numéricos que pueden ser medidos y ordenados, como la edad, el ingreso o la altura, y sobre los cuales se pueden aplicar operaciones aritméticas.

Cursor: Objeto de la interfaz de bases de datos que permite ejecutar sentencias SQL y recorrer los resultados devueltos por una consulta.

D

DataFrame: Estructura de datos bidimensional de Pandas, equivalente a una tabla con filas y columnas etiquetadas, que permite manipular datos tabulares de forma eficiente.

Dataset: Colección estructurada de datos utilizada para entrenamiento, prueba o análisis; puede estar en formato CSV, base de datos, JSON u otros formatos.

Datos: Conjunto de hechos, números, palabras, observaciones u otra información útil.

Datos atípicos: Valores que se alejan significativamente del resto de las observaciones de un dataset, detectados mediante métodos como IQR o Z-score, y que pueden distorsionar el análisis.

Datos faltantes: Valores ausentes en un conjunto de datos, representados generalmente como NaN o NULL, que deben ser tratados mediante imputación o eliminación antes del análisis.

Determinantes: Valor escalar calculado a partir de una matriz cuadrada que indica si la matriz es invertible y describe propiedades geométricas de la transformación lineal que representa.

Dimensionalidad: Número de variables o características que describe cada registro en un dataset; una alta dimensionalidad puede causar problemas computacionales conocidos como la maldición de la dimensionalidad.

Distribución: Descripción matemática o gráfica de cómo se dispersan los valores de una variable; puede ser normal, uniforme, sesgada, entre otras, y se visualiza con histogramas o KDE.

Duplicados: Filas idénticas o casi idénticas dentro de un dataset que pueden sesgar los resultados del análisis y deben ser detectados con métodos como `uplicated()` y eliminados.

E

EDA: Análisis Exploratorio de Datos (Exploratory Data Analysis); etapa inicial del proceso de ciencia de datos donde se examinan los datos de forma sistemática para entender su estructura, calidad y relaciones antes de modelar.

Ecosistema de datos: Los distintos elementos que interactúan entre sí para producir, gestionar, almacenar, organizar, analizar y compartir datos.

Estadísticas: Medidas numéricas que resumen propiedades de un conjunto de datos, como la media, mediana, desviación estándar, mínimo y máximo; en Pandas se obtienen con `describe()`.

Estructurados (Datos): Datos organizados en un formato predefinido de filas y columnas, como los almacenados en bases de datos relacionales o archivos CSV, que facilitan su consulta y análisis.

Expresión regular: Secuencia de caracteres que define un patrón de búsqueda en cadenas de texto; se usa en ETL para extraer, validar o reemplazar datos como teléfonos, fechas o códigos postales.

Extracción de datos: Primera fase del proceso ETL en la que los datos se obtienen desde una fuente original, como un archivo CSV, una base de datos o una API, para ser procesados.

ETL: Proceso compuesto por tres fases: Extracción, Transformación y Carga (Extract, Transform, Load); paradigma estándar para mover datos desde fuentes origen hasta destinos listos para análisis.

F

Filtrado: Selección de filas de un DataFrame o array que cumplen una condición booleana específica, como `df[df['age'] > 18]` o `array[array > 3]`.

Frecuencia: Número de veces que un valor o rango de valores aparece en un conjunto de datos; es la base de histogramas y tablas de distribución de frecuencias.

Funciones: Bloques de código reutilizables que encapsulan una lógica específica, aceptan parámetros y devuelven resultados; en ciencia de datos son clave para automatizar transformaciones y análisis.

G

Groupby: Método de Pandas que agrupa un DataFrame por los valores de una o más columnas para luego aplicar funciones de agregación como `mean()`, `sum()` o `agg()` a cada grupo.

H

Heatmap: Visualización que representa una matriz de valores mediante una escala de color, muy utilizada para mostrar matrices de correlación entre variables numéricas.

Histograma: Gráfica de barras que muestra la distribución de frecuencias de una variable numérica al dividir su rango en intervalos (bins) y contar cuántos datos caen en cada uno.

I

Imputación: Técnica de tratamiento de datos faltantes que reemplaza los valores NaN por un valor calculado, como la media, mediana o moda de la columna correspondiente.

Indexación: Mecanismo para acceder a elementos específicos de un array o DataFrame usando posiciones numéricas o etiquetas, como `array[1, 2]` o `df.loc['fila', 'columna']`.

Ingeniería de datos: Disciplina que se encarga de diseñar y construir los sistemas y pipelines que recopilan, almacenan y preparan los datos para que puedan ser analizados.

Insight: Hallazgo significativo obtenido del análisis de datos que proporciona comprensión nueva o accionable sobre un fenómeno, proceso o comportamiento.

Inteligencia artificial: Rama de la informática que busca desarrollar sistemas capaces de realizar tareas que normalmente requieren inteligencia humana, como reconocimiento de patrones, aprendizaje y toma de decisiones.

IQR: Rango Intercuartílico (Interquartile Range); diferencia entre el tercer cuartil (Q3) y el primer cuartil (Q1) de una distribución; se usa para detectar valores atípicos.

J

JSON: Formato de intercambio de datos basado en texto, estructurado como pares clave-valor y listas; muy usado en APIs y como formato de almacenamiento semi-estructurado.

Jupyter: Entorno de desarrollo interactivo basado en notebooks que permite combinar código ejecutable, texto enriquecido y visualizaciones en un mismo documento, ampliamente usado en ciencia de datos.

K

KDE: Estimación de Densidad de Kernel (Kernel Density Estimation); técnica no paramétrica para estimar la función de densidad de probabilidad de una variable continua, usada en pairplots y análisis univariado.

L

Lambda: Función anónima de una sola expresión definida en Python con la palabra clave lambda; usada en ciencia de datos para aplicar transformaciones rápidas a columnas o series.

Limpieza de datos: Proceso de detectar y corregir registros erróneos, incompletos, duplicados o mal formateados en un dataset para mejorar su calidad antes del análisis.

Logaritmo: Operación matemática inversa a la exponenciación; en ciencia de datos se usa para normalizar distribuciones sesgadas y como característica en modelos de machine learning.

M

Machine learning: Subcampo de la inteligencia artificial que permite a los sistemas aprender patrones a partir de datos sin ser explícitamente programados para cada tarea.

Matrices: Arreglos bidimensionales de números organizados en filas y columnas sobre los cuales se pueden realizar operaciones como suma, multiplicación, transposición e inversión.

Matplotlib: Biblioteca de Python para crear visualizaciones estáticas, como histogramas, gráficas de líneas, diagramas de dispersión y boxplots, mediante una interfaz similar a MATLAB.

Media: Promedio aritmético de un conjunto de valores; medida de tendencia central sensible a valores atípicos, calculada como la suma de todos los valores dividida entre el número de observaciones.

Mediana: Valor central de un conjunto de datos ordenado; medida de tendencia central más robusta que la media ante la presencia de valores atípicos.

Metadatos: Datos que describen otros datos, como el nombre de las columnas, los tipos de dato, el número de registros y las restricciones de un dataset o tabla.

Moda: Valor que aparece con mayor frecuencia en un conjunto de datos; usada como estrategia de imputación para variables categóricas con valores faltantes.

N

No estructurados (Datos): Datos que no tienen un formato predefinido de filas y columnas, como imágenes, audio, vídeo o texto libre, y que requieren técnicas especiales para ser analizados.

Nomenclatura: Sistema de nombres y convenciones utilizados para identificar variables, columnas, funciones y archivos de forma consistente y legible dentro de un proyecto de datos.

NoSQL: Categoría de sistemas de gestión de bases de datos que no usan el modelo relacional ni SQL como lenguaje principal; incluye bases de datos de documentos, grafos, columnas y clave-valor.

NumPy: Biblioteca fundamental de Python para computación numérica que proporciona el objeto ndarray, operaciones vectorizadas y funciones matemáticas de alto rendimiento usadas ampliamente en ciencia de datos.

Nulos: Valores ausentes o indefinidos en un dataset representados como NaN (Not a Number) en Pandas o NULL en SQL; su tratamiento es una tarea esencial en la limpieza de datos.

O

Operaciones: Conjunto de transformaciones matemáticas o lógicas aplicadas a arrays, vectores o matrices, como suma, resta, multiplicación, división, exponenciación y operaciones trigonométricas.

Outlier: Valor atípico que se aleja significativamente de la distribución general de los datos; puede ser legítimo o resultado de un error, y su tratamiento impacta directamente los resultados del análisis.

P

Pairplot: Matriz de gráficas de dispersión que muestra las relaciones entre todos los pares de variables numéricas de un dataset, generada con Seaborn, útil en la fase multivariada del EDA.

Pandas: Biblioteca de Python que proporciona estructuras de datos (Series y DataFrame) y herramientas para manipulación, limpieza, agrupación y análisis de datos tabulares.

Patrones: Regularidades o tendencias repetibles detectadas en los datos mediante análisis estadístico o visual que permiten hacer inferencias y predicciones.

Pipeline: Secuencia encadenada de pasos de procesamiento de datos donde la salida de cada etapa es la entrada de la siguiente; garantiza reproducibilidad y modularidad en proyectos ETL o de ML.

Predicciones: Estimaciones sobre valores desconocidos o futuros generadas por un modelo entrenado con datos históricos, aplicando los patrones aprendidos a nuevas observaciones.

Problema: Pregunta o situación que el análisis de datos busca resolver mediante la recopilación, procesamiento e interpretación de información relevante.

Python: Lenguaje de programación de alto nivel, interpretado y de propósito general, ampliamente adoptado en ciencia de datos por su ecosistema de bibliotecas como NumPy, Pandas, Matplotlib y Scikit-learn.

Q

Query: Consulta estructurada escrita en SQL u otro lenguaje que solicita, filtra, agrupa u ordena datos almacenados en una base de datos.

R

R (Lenguaje): Lenguaje de programación y entorno de software libre especializado en computación estadística y gráficas, ampliamente utilizado en análisis de datos e investigación científica.

Raíz: Operación matemática que calcula la raíz cuadrada (u otro índice) de un número o array; en NumPy se implementa con `np.sqrt()` y se usa en normalización y métricas de error.

Registro: Fila individual de un dataset tabular que representa una observación o instancia; contiene los valores de cada variable o atributo para esa entidad específica.

Relaciones (En datos): Vínculos lógicos entre tablas de una base de datos relacional o entre variables de un dataset que permiten combinar o correlacionar información de distintas fuentes.

Reshape: Operación que cambia la forma dimensional de un array sin modificar sus datos, como convertir un vector de 9 elementos en una matriz 3×3 usando `np.reshape()`.

S

Schema: Definición formal de la estructura de una base de datos o tabla, especificando los nombres de columnas, sus tipos de dato y restricciones como PRIMARY KEY o NOT NULL.

SciPy: Biblioteca de Python que extiende NumPy con funciones para álgebra lineal, estadística, optimización, señales y otras áreas científicas; incluye scipy.stats para análisis estadístico avanzado.

Scikit-learn: Biblioteca de Python para machine learning que proporciona herramientas para clasificación, regresión, clustering, reducción de dimensionalidad y evaluación de modelos.

Seaborn: Biblioteca de visualización estadística de Python construida sobre Matplotlib que facilita la creación de gráficas como heatmaps, pairplots y boxplots con sintaxis concisa.

Semi-estructurados (Datos): Datos que tienen cierta organización pero no un esquema rígido de tablas, como XML, JSON o HTML, que contienen etiquetas o marcadores que separan elementos semánticos.

Series: Estructura de datos unidimensional de Pandas con etiquetas (índice), equivalente a una columna de DataFrame, sobre la cual se pueden aplicar operaciones vectorizadas.

SQL: Lenguaje de Consulta Estructurada (Structured Query Language); estándar para definir, manipular y consultar datos en bases de datos relacionales.

SQLite: Sistema de gestión de bases de datos relacional ligero, sin servidor y de archivo único; muy usado en prototipado y en pipelines ETL de ciencia de datos con Python.

Subrutinas: Bloques de código nombrados que realizan una tarea específica y pueden ser llamados múltiples veces desde distintos puntos de un programa, mejorando su modularidad.

T

Tabla: Estructura de datos bidimensional en una base de datos relacional compuesta por filas (registros) y columnas (atributos), almacenada y consultada mediante SQL.

Timestamp: Representación numérica o textual de un punto específico en el tiempo; en Unix timestamp corresponde al número de segundos transcurridos desde el 1 de enero de 1970.

Toma de decisiones basada en datos: Uso de datos para guiar la estrategia empresarial.

Transformación de datos: Fase del proceso ETL en la que los datos extraídos son convertidos, limpiados o enriquecidos para cumplir con los requisitos del sistema de destino o del análisis.

Transpuesta: Operación sobre una matriz que intercambia sus filas por columnas; en NumPy se obtiene con `.T` o `np.transpose()` y es fundamental en álgebra lineal.

Tratamiento de datos: Conjunto de operaciones aplicadas a un dataset para corregir errores, manejar nulos, eliminar duplicados y tratar outliers, garantizando la calidad de los datos antes del análisis.

U

Umbral: Valor límite utilizado en algoritmos de limpieza o clasificación para separar datos válidos de inválidos, o para decidir a qué categoría pertenece una observación.

V

Variables: Nombres simbólicos que almacenan valores en un programa; en ciencia de datos también se refiere a las columnas o características de un dataset.

Vectores: Arrays unidimensionales que representan magnitudes con dirección en el espacio matemático; en NumPy se implementan como `ndarray` de una dimensión y son la base del álgebra lineal computacional.

Visualización: Representación gráfica de datos o resultados de análisis mediante gráficas, mapas o diagramas para facilitar la comprensión e interpretación de patrones e insights.

Valores atípicos: Ver: Datos atípicos y Outlier. Observaciones que se desvían marcadamente del comportamiento general del dataset y pueden ser detectadas mediante Z-score o el método IQR.

W

Wrangling: Proceso de limpieza y transformación de datos crudos en un formato estructurado y utilizable para el análisis; también conocido como data munging.

X

XML: Lenguaje de Marcado Extensible (eXtensible Markup Language); formato de datos semi-estructurado que usa etiquetas jerárquicas para representar información y es común en intercambio de datos entre sistemas.

Y

ydata-profiling: Biblioteca de Python que genera automáticamente reportes completos de EDA a partir de un `DataFrame` de Pandas, incluyendo estadísticas, distribuciones, correlaciones y valores faltantes.

Z

Z-score: Medida estadística que indica cuántas desviaciones estándar se aleja un valor de la media de su distribución; se usa para detectar y filtrar valores atípicos extremos en datasets.